Projet IA : Détection des anomalies dans les commandes d'achat (Fraude Achat)

1 Introduction

Le contrôle des achats dans une entreprise est un processus sensible, car il implique des flux financiers importants et des risques de fraude. Le projet consiste à détecter automatiquement les **anomalies dans les commandes d'achat** afin de prévenir des fraudes telles que :

- Les commandes **suspectes** (montant élevé non justifié, fournisseur inconnu, etc.)
- Les commandes **frauduleuses**, comme celles passées pour des fournisseurs fictifs ou pour détourner des fonds.

Ce projet s'inscrit dans le cadre du **processus Procure-to-Pay (P2P)** : de la demande d'achat à la validation de paiement, en passant par la commande et la réception des biens ou services. Le but est de renforcer le **contrôle interne des achats**, d'assurer la **séparation des tâches** et d'appliquer les principes de **COSO** pour la prévention des fraudes.

La variable cible de ce projet est **`Commande`**, qui prend trois valeurs possibles :

- `normale`
- `suspecte`
- `frauduleuse`

Nous utilisons pour ce projet :

- Le **Purchase Order Fraud Dataset** disponible sur Kaggle
- Des **données simulées** pour compléter et illustrer le processus P2P

2 Dataset et Explications

Le dataset contient des informations clés pour détecter la fraude dans les commandes d'achat. Voici les colonnes et leur rôle :

Colonne	Description	Importance pour la détection de fraude
`OrderID`	Identifiant unique de la commande	Permet de suivre chaque commande individuellement
`SupplierID`	Identifiant du fournisseur	Permet de repérer les fournisseurs suspects ou fictifs
`Amount`	Montant de la commande	Les montants anormalement élevés peuvent indiquer une fraude

Colonne	Description	Importance pour la détection de fraude
`PaymentTerms`	Conditions de paiement (en jours)	Les délais inhabituels peuvent révéler des comportements suspects
`POType`	Type de commande (Standard, Urgent, Backorder)	Les commandes urgentes ou non standards peuvent être suspectes
`Country`	Pays du fournisseur	Identifier les fournisseurs internationaux ou à risque
`AnomalyScore`	Score d'anomalie simulé (0-1)	Score calculé pour détecter le risque de fraude
`Commande`	Classe cible (`normale`, `suspecte`, `frauduleuse`)	Ce que le modèle doit prédire

Exemple de données

OrderID	SupplierID	Amount	PaymentTerms	POType	Country	AnomalyScore	Commande
1001	SUP001	1200	30	Standard	France	0.05	normale
1002	SUP002	5000	15	Urgent	USA	0.85	frauduleuse
1003	SUP003	250	30	Standard	Morocco	0.15	suspecte
1004	SUP004	7500	60	Standard	China	0.92	frauduleuse
1005	SUP001	600	30	Standard	France	0.10	normale

Le fichier complet de 500 lignes est sauvegardé sous `purchase_orders_simulated.csv`.

3 Processus P2P et lien avec la fraude

Le **processus Procure-to-Pay (P2P)** comprend plusieurs étapes :

1. **Demande d'achat** : un employé demande un produit ou service.
2. **Validation de la demande** : vérification par le manager ou le département achat.
3. **Passation de commande** : la commande est envoyée au fournisseur.
4. **Réception des biens/services** : contrôle que la livraison correspond à la commande.
5. **Paiement** : paiement effectué uniquement après vérification.

Les risques de fraude interviennent principalement dans :

- La **passation de commande** (commande fictive, fournisseur fantôme)

- La **validation et séparation des tâches** (un employé seul peut contourner les contrôles)

L'IA aide à détecter automatiquement les commandes suspectes ou frauduleuses à partir des **patterns dans les données** (montants, fournisseurs, pays, types de commande, scores d'anomalie).

4 Méthodologie IA

4.1 Choix du modèle

Pour ce projet, nous utilisons une **classification supervisée**. Les modèles possibles sont :

- **RandomForestClassifier** : efficace pour les données tabulaires et les anomalies.
- **Logistic Regression** : simple et interprétable pour vérifier les facteurs de risque.

4.2 Préparation des données

- Encodage des variables catégorielles (`SupplierID`, `POType`, `Country`) avec `LabelEncoder`.
- Séparation en **features** (`Amount`, `PaymentTerms`, `POType`, etc.) et **cible** (`Commande`).
- Division en **train set** et **test set** (80%/20%).

5 Code Python pour la classification

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix

# Charger les données
df = pd.read_csv("purchase_orders_simulated.csv")

# Encoder les variables catégorielles
le_supplier = LabelEncoder()
df['SupplierID'] = le_supplier.fit_transform(df['SupplierID'])

le_po = LabelEncoder()
df['POType'] = le_po.fit_transform(df['POType'])

le_country = LabelEncoder()
df['Country'] = le_country.fit_transform(df['Country'])

# Features et cible
X = df[['SupplierID', 'Amount', 'PaymentTerms', 'POType', 'Country',
'AnomalyScore']]
y = df['Commande']
```

```
# Diviser en train/test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# Modèle RandomForest
model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

# Prédictions
y_pred = model.predict(X_test)

# Evaluation
print("Confusion Matrix:")
print(confusion_matrix(y_test, y_pred))
print("\nClassification Report:")
print(classification_report(y_test, y_pred))
```

6 Explications du code

- **LabelEncoder** : transforme les variables texte en valeurs numériques pour le modèle.
- **RandomForestClassifier** : crée plusieurs arbres de décision pour améliorer la précision et réduire le sur-apprentissage.
- **train_test_split** : sépare les données pour entraîner le modèle et le tester sur des données non vues.
- **confusion_matrix** : montre combien de commandes ont été correctement classées par catégorie.
- **classification_report** : donne précision, rappel et F1-score pour chaque classe (`normale`, `suspecte`, `frauduleuse`).

7 Résultats attendus

- Détecter automatiquement les commandes suspectes ou frauduleuses.
- Réduire les risques de fraude fournisseur fantôme et erreurs dans le P2P.
- Fournir une base pour des **alertes automatisées** dans le système achat.

Les résultats peuvent être visualisés à travers la **matrice de confusion** et le **rapport de classification** pour mesurer l'efficacité du modèle.

8 Conclusion

Ce projet montre comment l'IA peut renforcer le **contrôle interne** dans les achats, détecter la fraude et améliorer la sécurité financière.
Grâce aux données simulées et aux méthodes de classification, il est possible de :

- Identifier rapidement les commandes à risque
- Soutenir les décisions du département achat

- Appliquer les bonnes pratiques COSO dans le processus P2P